# Sortowanie plików sekwencyjnych metodą scalania naturalnego

Jerzy Szyjut

26.11.2024

## 1 Wybór implementacji

W ramach mojego projektu zaimplementowałem metodę scalania naturalnego na trzech taśmach w schemacie 2+1. Jako typ rekordu wylosowałem 5 liczb, które są sortowane po średniej arytmetycznej, liczby zapisywane są w 4-bajtowym typie int. Program zaimplementowałem w języku C++.

## 2 Wprowadzenie teoretyczne

## 2.1 Wstęp

Sortowanie przez scalanie składa się z faz, na każdą z faz składają się dwa etapy, etap rozdziału i etap scalania. Etapy te po kolei zmniejszają liczbę serii, czyli niemalejących ciągów liczb. Algorytm ten z każdą fazą zmniejsza liczbę serii (i zwiększa ich długość), aż skończy na jednej serii o długości całego pliku.

Stałe używane później w sprawozdaniu:

- $\bullet~N$  liczba rekordów w pliku
- $\bullet$  B rozmiar bloku w bajtach
- $\bullet$  R rozmiar rekordu w bajtach
- $\bullet$  r liczba serii występujących w pliku
- b = B/R liczba rekordów na blok

#### 2.2 Rozdzielanie

W etapie rozdzielania, rozdzielamy serie z jednej taśmy (na początku tą taśmą jest plik wejściowy) na dwie taśmy. Robimy to w ten sposób

- 1. Przenosimy liczby na pierwszą z dwóch taśm
- 2. Napotykamy koniec serii, następne liczby przenosimy na drugą z dwóch taśm
- 3. Napotykamy koniec serii, wracamy do przenoszenia liczb na pierwszą z taśm
- 4. Robimy tak, aż nie wyczerpiemy liczb na pierwszej z taśm

Przykładowo (znaki | są tylko, aby podkreślic, gdzie kończą się serie):

Taśma wejściowa - [46 59 77 | 55 75 | 44 57 | 73 ]

Wedle algorytmu rozdzielamy liczby na dwie taśmy zmieniając taśmy po napotkaniu końca serii

1.

```
T1 - [ 46 59 77 ]

T2 - []

2.

T1 - [ 46 59 77 ]

T2 - [ 55 75 ]

3.

T1 - [ 46 59 77 | 44 57 ]

T2 - [ 55 75 ]

4.

T1 - [ 46 59 77 | 44 57 ]

T2 - [ 55 75 | 73 ]
```

### 2.3 Scalanie

W etapie rozdzielania, scalamy serie z dwóch taśm na jedną. W tym etapi zmniejszamy liczbę serii i je wydłużamy. Algorytm scalania jest bardzo podobny do tego z algorytmu merge sort. Scalamy pierwszą serię taśmy pierwszę z pierwszą serią taśmy drugiej, później drugą z drugą itd. W przypadku, gdy na drugiej taśmie nie ma odpowiadającej serii, dopełniamy taśmę tą "samotną"serią.

Przykładowo (znaki | są tylko, aby podkreślic, gdzie kończą się serie):

```
T1 - [ 46\ 59\ 77\ |\ 44\ 57\ ]
T2 - [ 55\ 75\ |\ 73\ ]
Taśma wyjściowa - [ 46\ 55\ 59\ 75\ 77\ |\ 44\ 57\ 73\ ]
```

#### 2.4 Analiza

Algorytm ten pozwala na sortowanie danych o rozmiarach znacznie przekraczających rozmiar pamięci operacyjnej, gdy zastosuje ładowanie danych z i do taśm blokami (na wzór stronnicowania i pamięci wymiany). W wypadku tego algorytmu zużywamy B pamięci RAM i  $N \times R$  pamięci dyskowej.

Liczbę faz potrzebnych do posortowania pliku można obliczyć za pomocą wzoru

$$\lceil \log_2 r \rceil$$

Liczby operacji dyskowej w przypadku pesymistycznym można obliczyć za pomocą wzoru

$$4N\lceil \log_2 N \rceil/b$$

Liczby operacji dyskowej w przypadku średnim można obliczyć za pomocą wzoru

$$4N\lceil \log_2 r \rceil/b$$

# 3 Specyfikacja formatu pliku

Plik sekwencyjny z danymi jest plikiem binarny i zawiera kolejno rekordy jeden po drugim w 4-bajtowej postaci binarnej reprezentującej liczby. Jeden rekord zawiera dokładnie 20 bajtów. Plik nie zawiera metadanych, nagłówków rekordów czy separatorów. Program odczytuje i zapisuje dane z pliku za pomocą klasy Tape. Odczyt z pliku odbywa się w blokach o dowolnej wielkości będącej wielokrotnością rekordu.

## 4 Sposób prezentacji wyników działania programu

Menu wyboru akcji w programie jest wywoływane w momentach kluczowych dla algorytmu (przed uruchomieniem algorytmu, po każdym rozdziale, scalaniu i po posortowaniu pliku). Menu pozwala na nadpisywanie taśm oraz podglądywanie taśm oraz wybór momentów wstrzymywania algorytmu. Po wykonaniu się programu prezentowane są statystyki.

#### 4.1 Menu

```
Stopped before sorting
Stopped by debug controller. Available commands:

n - continue
p - print tape
a - add random records to tape
i - add records to tape manually
b - create binary file with numbers
c - change tape to load from specific file
s - stop before sorting (toggle). Currently: on
m - stop after merge (toggle). Currently: off
d - stop after distribute (toggle). Currently: off
o - stop after sort (toggle). Currently: off
q - quit
```

## 4.2 Wyświetlanie zawartości taśmy

```
Choose tape to print:
1 - input tape
2 - tape 1
3 - tape 2
4 - output tape
q - quit
Choice: 1
Tape: input.dat
Mode: read
Current record index: 0
Records:
  6644 1226 9184 7828 9187
                             average: 6813.8
  8595 4649 6371 6095 7326
                             average: 6607.2
  3420 5301 2729 7611 8681
                             average: 5548.4
  4216\ 6071\ 1415\ 2995\ 4827
                             average: 3904.8
  5643 8224 5335 9136 4675
                             average: 6602.6
  1599\ \ 2547\ \ 2773\ \ 3394\ \ 1692
                             average: 2401
  9271\ 6197\ 4500\ 2670\ 9359
                             average: 6399.4 ]
  3951 6471 3729 4091 4223
                             average: 4493
 4818 910 3991 3534 7029
                            average: 4056.4
 9118 8922 7107 9058 3331
                             average: 7507.2 ]
```

#### 4.3 Końcowe statystyki

```
Number of series: 504
Expected number of phases: 9
Actual number of phases: 8
Expected number of read/write operations: 3600
Actual number of read operations: 1809
```

Actual number of write operations: 1907 Actual number of read/write operations: 3716

# 5 Eksperyment

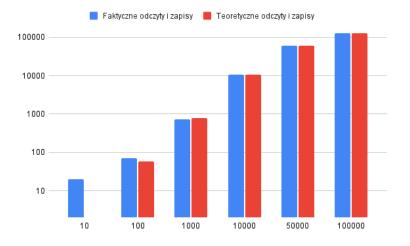
Przy pomocy programu przeprowadziłem eksperymenty losując rekordy przy tym samym ziarnie generatora liczb losowych. Zrobiłem tak dla rozmiarów stron 10, 50 i 100. Następnie wyniki mojego algorytmu porównałem z oczekiwanymi wynikami wynikającymi ze wzorów.

b	N	r	odczyty	zapisy	o+z	liczba faz	t. o+z	t. liczba faz
10	10	4	7	6	13	1	8	2
10	100	44	129	125	254	6	240	6
10	1000	505	1810	1808	3618	9	3600	9
10	10000	4958	26015	26011	52026	13	52000	13
10	50000	24944	150020	150015	300035	15	300000	15
10	100000	49983	320022	320015	640037	16	640000	16
50	10	6	10	10	20	3	2	3
50	100	50	37	35	72	6	58	6
50	1000	519	371	369	740	9	800	10
50	10000	4948	5216	5213	10429	13	10429	13
50	50000	25018	30021	30015	60036	15	60000	15
50	100000	49996	64037	64032	128069	16	128000	16
100	10	3	7	7	14	2	0	2
100	100	51	23	21	44	6	24	6
100	1000	484	191	189	380	9	360	9
100	10000	5014	2613	2613	5230	13	5200	13
100	50000	24930	15036	15030	30066	15	30000	15
100	100000	50014	32034	32029	64037	16	64063	16

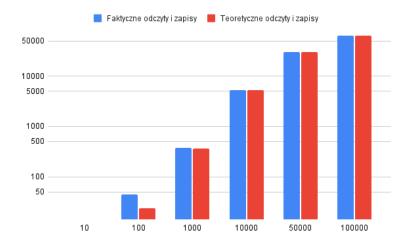
Dla b=10



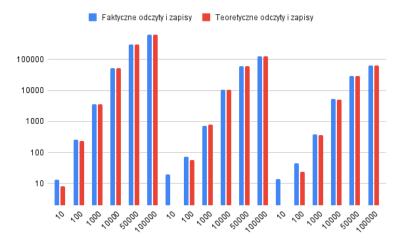
Dla b=50



Dla b = 100



Dla  $b=10,\,b=50$ ib=100



Dla danych powyżej widać, że wyniki programu są zbliżone do teoretycznych wyników wyliczonych ze wzorów. Algorytm dokonuje kilku nadmiarowych zapisów i odczytów, ale ich liczba nie wzrasta szybko, ma marginalny narzut na całkowitą liczbę zapisów i odczytów (dla wyższych wyników poniżej 1%). Wyniki na wykresach przedstawiłem na skali logarytmicznej, można wywnioskować z nich, że ilość odczytów i zapisów jest

zbliżona do zależności liniowej. Liczba faz nie zmienia się w zależności od wielkości bloków, jedynie w zależności od liczby serii i rekordów.

# 6 Wnioski

Wyniki eksperymentu można uznać za zbliżone do wyników teoretycznych i zgodne z oczekiwaniami, drobne odstępstwa wynikają z szczegółów implementacyjnych algorytmu. Liczba operacji zapisu i odczytu jest odwrotnie proporcjonalna do rozmiaru bloku, a rozmiar bloku nie ma wpływu na liczbę faz.